

PERTEMUAN 4 DATA PREPARATION

NAMA : SYIFA FIBRIANA SYAM


NIM : 231011401049

KELAS : 05TPLE017

MATKUL : MACHINE LEARNING

TOPIK : Penerapan Data Cleaning, EDA, dan Pembuatan Fitur Turunan untuk Prediksi Kelulusan Mahasiswa

Collection (Pengumpulan Data)



```
file > data-mahasiswa.csv
You last wrote 11 author (You)
1  IPK,Jumlah_Absensi,Waktu_Belajar_Jam,Lulus
2  3.8,3,10,1
3  2.5,8,5,0
4  3.4,4,7,1
5  2.1,12,2,0
6  3.9,2,12,1
7  2.8,6,4,0
8  3.2,5,8,1
9  2.7,7,3,0
10 3.6,4,9,1
11 2.3,9,4,0
12 3.7,3,11,1
13 2.4,10,3,0
14 3.5,4,8,1
15 2.2,11,2,0
16 3.8,3,10,1
17 2.9,7,5,0
18 3.3,5,8,1
```


- Tujuan: Menghimpun data mahasiswa yang relevan dan legal untuk analisis faktor kelulusan.
- Praktik: Dataset data-mahasiswa.csv dikumpulkan berisi 200 baris data dengan variabel IPK, Waktu_Belajar_Jam, Jumlah_Absensi, dan Lulus.
- Catatan: Data disimpan secara lokal dan digunakan hanya untuk keperluan akademik.

Dataset yang digunakan bernama data-mahasiswa.csv, berisi beberapa variabel seperti:

- IPK : Indeks Prestasi Kumulatif mahasiswa (float)
- Waktu_Belajar_Jam : Rata-rata waktu belajar per minggu (jam)
- Jumlah_Absensi : Jumlah kehadiran mahasiswa selama satu semester
- Lulus : Status kelulusan mahasiswa (Ya atau Tidak)

Tujuan analisis ini adalah untuk memahami faktor-faktor yang memengaruhi kelulusan mahasiswa serta membuat fitur baru yang dapat meningkatkan performa model prediksi.

Data Cleaning dan Persiapan



```

1 IPK,Jumlah_Absensi,Waktu_Belajar_Jam,Lulus,Rasio_Absensi,IPK_x_Study
2 3.8,3,10,1,0.21428571428571427,38.0
3 2.5,8,5,0,0.5714285714285714,12.5
4 3.4,4,7,1,0.2857142857142857,23.8
5 2.1,12,2,0,0.8571428571428571,4.2
6 3.9,2,12,1,0.14285714285714285,46.8
7 2.8,6,4,0,0.42857142857142855,33.2
8 3.2,5,8,1,0.35714285714285715,25.6
9 2.7,7,9,0,0.5,8.100000000000001
10 3.6,4,9,1,0.2857142857142857,32.4
11 2.3,9,4,0,0.6428571428571429,9.2
12 3.7,3,11,1,0.21428571428571427,40.7
13 2.4,10,3,0,0.7142857142857143,7.199999999999999
14 3.5,4,8,1,0.2857142857142857,28.0
15 2.2,11,2,0,0.7857142857142857,4.4
16 2.9,7,5,0,0.5,14.5
17 3.3,6,6,1,0.35714285714285715,26.4
18 2.6,8,4,0,0.5714285714285714,10.4
19 2.1,12,3,0,0.8571428571428571,6.300000000000001
20 2.7,9,4,0,0.6428571428571429,10.8
21 3.4,5,7,1,0.35714285714285715,23.8
22 2.5,10,3,0,0.7142857142857143,7.5
23 3.8,3,11,1,0.21428571428571427,41.8
24 2.3,9,2,0,0.6428571428571429,4.6
25 2.8,7,4,0,0.5,33.2
26 3.7,3,9,1,0.21428571428571427,33.300000000000004
27 2.1,11,3,0,0.7857142857142857,6.300000000000001
  
```

Pada tahap awal, dataset diperiksa untuk memastikan tidak ada **missing value** dan **data duplikat**. Selanjutnya dilakukan **penghapusan duplikat** dan pengecekan distribusi data.

Sebelumnya, ketika dataset hanya berisi sekitar 50 baris, proses pemisahan data (train-test split) sempat mengalami error karena jumlah data yang terlalu kecil untuk stratifikasi label *Lulus*. Oleh karena itu, dataset kemudian **ditingkatkan menjadi 200 baris** agar distribusi label lebih seimbang dan model dapat melakukan pembelajaran secara optimal.

