

## PERTEMUAN 6 Random Forest

Nama : Syifa Fibriana Syam

NIM : 231011401049

KELAS : 05TPLE017

MATKUL : MACHINE LEARNING

TOPIK : Evaluasi dan Optimasi Model Random Forest untuk Klasifikasi dengan Analisis Kinerja dan Threshold

Tujuan dari eksperimen ini adalah untuk membangun model klasifikasi menggunakan algoritma **Random Forest (RF)** guna memprediksi **kelulusan mahasiswa** berdasarkan fitur akademik seperti IPK, absensi, dan waktu belajar.

Pendekatan ini dilakukan dengan membuat **baseline model**, melakukan **tuning dua parameter utama**, dan mengevaluasi hasilnya menggunakan **F1-score, confusion matrix, ROC curve**, serta **Precision-Recall (PR) curve**.

### Dataset dan Fitur

```
pt6.py  X
pt6.py > ...
You, last week | 1 author (You)
1 import pandas as pd          You, last week * Upload reqpredict.py ...
2 from sklearn.model_selection import train_test_split
3
4 df = pd.read_csv("file/processed_kelulusan.csv")
5 X = df.drop("Lulus", axis=1)
6 y = df["Lulus"]
7
8 # split: 70/15/15
9 X_train, X_temp, y_train, y_temp = train_test_split(
10     X, y, test_size=0.30, stratify=y, random_state=42
11 )
12 X_val, X_test, y_val, y_test = train_test_split(
13     X_temp, y_temp, test_size=0.50, stratify=y_temp, random_state=42
14 )
15 print(X_train.shape, X_val.shape, X_test.shape)
16
17 from sklearn.pipeline import Pipeline
18 from sklearn.compose import ColumnTransformer
19 from sklearn.preprocessing import StandardScaler
20 from sklearn.impute import SimpleImputer
21 from sklearn.ensemble import RandomForestClassifier
22 from sklearn.metrics import f1_score, classification_report
23
24 num_cols = X_train.select_dtypes(include="number").columns
```

Data yang digunakan terdiri dari beberapa fitur yang relevan terhadap performa akademik mahasiswa, yaitu:

- IPK – Indeks Prestasi Kumulatif
- Jumlah\_Absensi – Total ketidakhadiran mahasiswa
- Waktu\_Belajar\_Jam – Rata-rata waktu belajar per minggu
- IPK\_x\_Study – Hasil perkalian IPK dan waktu belajar
- Rasio\_Absensi – Rasio jumlah absensi terhadap total pertemuan

Target (label) berupa:

- 1 = Lulus
- 0 = Tidak Lulus

## Baseline Random Forest (RF)

```
PROBLEMS  OUTPUT  DEBUG CONSOLE  TERMINAL  PORTS  GITLENS

(.venv) PS C:\Machine Learning> & 'c:\Machine Learning\.venv\Scripts\python.exe' 'c:\Machine Learning\main.py'
Baseline RF - F1(val): 1.0
      precision    recall  f1-score   support

      0       1.000      1.000      1.000         5
      1       1.000      1.000      1.000         3

   accuracy               1.000         8
  macro avg       1.000      1.000      1.000         8
weighted avg       1.000      1.000      1.000         8

CV F1-macro (train): 1.0 ± 0.0
Fitting 5 folds for each of 12 candidates, totalling 60 fits
Best params: {'clf__max_depth': None, 'clf__min_samples_split': 2}
Best RF - F1(val): 1.0
F1(test): 1.0
      precision    recall  f1-score   support

      0       1.000      1.000      1.000         6
      1       1.000      1.000      1.000         2

   accuracy               1.000         8
  macro avg       1.000      1.000      1.000         8
weighted avg       1.000      1.000      1.000         8
```

Model awal (tanpa tuning parameter) sudah bisa **memprediksi semua data dengan benar 100%** pada data validasi.

Nilai **F1-score = 1.0** berarti *precision* dan *recall* sama-sama sempurna (tidak ada kesalahan klasifikasi).

## Cross Validation & Parameter Tuning

```

Confusion Matrix (test):
[[6 0]
 [0 2]]
ROC-AUC(test): 1.0
Top feature importance:
num__IPK: 0.2367
num__Rasio_Absensi: 0.2033
num__IPK_x_Study: 0.1933
num__Jumlah_Absensi: 0.1833
num__Waktu_Belajar_Jam: 0.1833
Model disimpan sebagai rf_model.pkl

```

|              |       |       |       |   |
|--------------|-------|-------|-------|---|
| 0            | 1.000 | 1.000 | 1.000 | 6 |
| 1            | 1.000 | 1.000 | 1.000 | 2 |
| accuracy     |       |       | 1.000 | 8 |
| macro avg    | 1.000 | 1.000 | 1.000 | 8 |
| weighted avg | 1.000 | 1.000 | 1.000 | 8 |

- Model diuji dengan *cross-validation* (5-fold), dan hasilnya stabil (tidak ada variasi/error).
- Parameter terbaik hasil tuning:
- **max\_depth = None** → artinya pohon tumbuh penuh, tidak dibatasi kedalamannya.
- **min\_samples\_split = 2** → minimal dua sampel untuk memecah node.

## Evaluasi pada Data Uji (Test Set)

```

Confusion Matrix (test):
[[6 0]
 [0 2]]
ROC-AUC(test): 1.0
Top feature importance:
num_IPK: 0.2367
num_Rasio_Absensi: 0.2033
num_IPK_x_Study: 0.1933
num_Jumlah_Absensi: 0.1833
num_Waktu_Belajar_Jam: 0.1833
Model disimpan sebagai rf_model.pkl
      0      1      2      3      4      5
      0      1.000      1.000      1.000      1.000      6
      1      1.000      1.000      1.000      1.000      2

      accuracy      1.000      1.000      1.000      1.000      8
      macro avg      1.000      1.000      1.000      1.000      8
      weighted avg      1.000      1.000      1.000      1.000      8

Confusion Matrix (test):
[[6 0]
 [0 2]]
ROC-AUC(test): 1.0
Top feature importance:
num_IPK: 0.2367

```

- Model berhasil **mengklasifikasikan semua data uji dengan benar.**
- Dari *confusion matrix*:
- 6 data benar-benar kelas 0 (misalnya "tidak lulus")
- 2 data benar-benar kelas 1 (misalnya "lulus")
- Tidak ada kesalahan prediksi sama sekali.
- **ROC-AUC = 1.0** menunjukkan performa sempurna — model membedakan dua kelas dengan sangat baik.

Fitur yang paling berpengaruh terhadap keputusan model:

1. **IPK (0.2367)** → paling dominan, jadi faktor IPK sangat menentukan hasil prediksi kelulusan.
2. **Rasio Absensi (0.2033)** dan **Jumlah Absensi (0.1833)** juga cukup besar pengaruhnya, artinya kehadiran berpengaruh terhadap peluang kelulusan.
3. **Waktu Belajar** dan **IPK x Study** memiliki kontribusi tambahan tapi sedikit lebih kecil.

## Feature Importance

```

Top feature importance:
num__IPK: 0.2367
num__Rasio_Absensi: 0.2033
num__IPK_x_Study: 0.1933
num__Jumlah_Absensi: 0.1833
num__Waktu_Belajar_Jam: 0.1833
Model disimpan sebagai rf_model.pkl
num__IPK: 0.2367
num__Rasio_Absensi: 0.2033
num__IPK_x_Study: 0.1933
num__Jumlah_Absensi: 0.1833
num__Waktu_Belajar_Jam: 0.1833
Model disimpan sebagai rf_model.pkl
num__IPK_x_Study: 0.1933
num__Jumlah_Absensi: 0.1833
num__Waktu_Belajar_Jam: 0.1833
Model disimpan sebagai rf_model.pkl
num__Jumlah_Absensi: 0.1833
num__Waktu_Belajar_Jam: 0.1833
Model disimpan sebagai rf_model.pkl
Hasil Prediksi: IKAN HIU MELAYANG-LAYANG, GK LULUS YA SAYANG
(.venv) PS C:\Machine Learning>

```

Fitur yang paling berpengaruh terhadap keputusan model:

1. **IPK (0.2367)** → paling dominan, jadi faktor IPK sangat menentukan hasil prediksi kelulusan.
2. **Rasio Absensi (0.2033)** dan **Jumlah Absensi (0.1833)** juga cukup besar pengaruhnya, artinya kehadiran berpengaruh terhadap peluang kelulusan.
3. **Waktu Belajar** dan **IPK x Study** memiliki kontribusi tambahan tapi sedikit lebih kecil.

#### KESIMPULAN :

- Model Random Forest kamu berhasil mengklasifikasi dengan akurasi 100% pada data train, validasi, dan test.
- Fitur yang paling berpengaruh adalah IPK dan Rasio Absensi.
- Tidak ada kesalahan klasifikasi (semua prediksi benar).
- Tapi perlu hati-hati — hasil sempurna bisa jadi karena jumlah data terlalu kecil (8 sampel) atau model overfitting.
- Rekomendasi: gunakan dataset yang lebih besar atau lakukan train-test split berbeda untuk memastikan model benar-benar general.